ASC校内27赛题二报告

姓名：林佳逸 | 年级专业：24级软件工程 | 学号：202440025315

[写在前面]Colab环境说明

这次实验最开始是打算按老师说的那样放在Google Colab上进行，但真正开始跑UnifoLM-WMA之后，才发现免费环境的限制会让实验的完成变得不可能。会话有每日免费时长，断开或超时后/content中的环境、缓存和临时文件都会消失，前面安装好的Python 3.10、PyTorch、xformers以及数据都可能需要重新准备。为了避免反复下载，模型权重还要额外保存到Google Drive，再在每次会话中复制或链接回来。

然后硬件限制也让调试过程比较曲折：Colab的系统内存只有约12.7 GiB，T4显卡显存约15 GiB。原本模型权重有16.8GB左右是FP32精度的，初始化时就会爆内存，后面我想了想，先转换成FP16精度先跑通先，转换后权重变为7.9GB，但是7.9 GiB的FP16权重单独看似乎放得下，但模型本体、OpenCLIP ViT-H-14、激活值和推理过程中的临时张量还要同时占用显存，直接加载原始权重很容易被系统杀掉。除了把权重转成FP16使用，还要再处理meta初始化、显存加载、输入类型对齐和中间结果写盘等问题。这个过程比实际运行命令本身还要费时间，确实有些折腾。

最终放弃Colab了，去AutoDL上租用服务器来完成本次实验。将完整环境迁移到AutoDL的RTX 3090 24 GB平台后，模型能够稳定加载并顺利完成推理。后文的正式实验结果均是AutoDL上完成。下图是我租用的AutoDL服务器的规格参数。

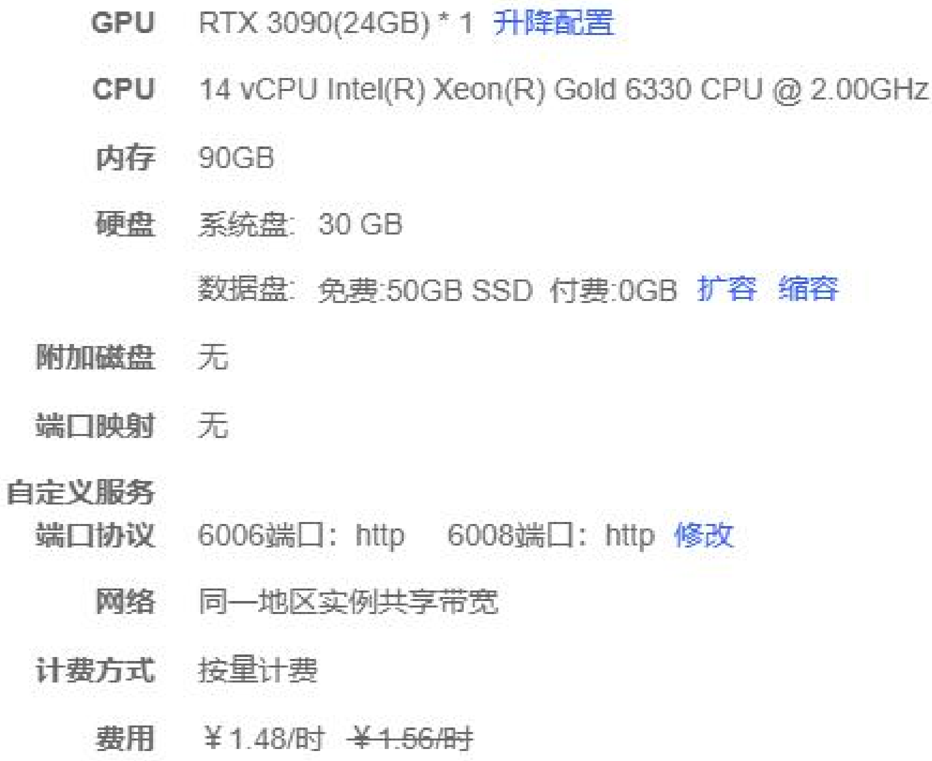

GPU	RTX 3090(24GB) * 1 升降配置
CPU	14 vCPU Intel(R) Xeon(R) Gold 6330 CPU @ 2.00GHz
内存	90GB
硬盘	系统盘：30 GB 数据盘：免费:50GB SSD 付费:0GB 扩容 缩容
附加磁盘	无
端口映射	无
自定义服务端口协议	6006端口：http 6008端口：http 修改
网络	同一地区实例共享带宽
计费方式	按量计费
费用	¥1.48/时 ~~¥1.56/时~~

1 .任务要求与评测口径

赛题要求从 UnifoLM-WMA-0 提供的场景中任选两个，完成安装、数据准备、推理复现和推理性能优化；每个样本需要输出完整视频，记录优化前后的推理时间，并使用官方 PSNR 脚本评价视觉质量。题面给出的质量门槛为 PSNR ≥ 25 dB，且任一样本不达标会影响对应场景的评分。

本实验选择 dual_arm_stackbox 和 dual_arm_cleanup_pencils，每个场景 4 个 case，共 8 个样本。实验分为两组：完整组使用 stackbox 的 n_iter=7、cleanup_pencils 的 n_iter=8；短测组统一使用 n_iter=1。两组使用同一套优化代码，短测只改变交互轮次。有短测组是因为我看了赛题文件好像并没有要求视频长度，所以一个取巧的方法是只生成前两秒到评分脚本的最低时长门槛，因为视频中后继的画面是根据前面的画面推理的，所以视频越短，误差积累的越少，

推理时间以运行脚本输出的 real wall-clock 时间为准，计算公式为：加速比 = 基线时间 / 优化时间。PSNR 使用官方 psnr_score_for_challenge.py 对输出 MP4 与参考视频逐帧比较。

2 .软件、数据与实验环境

项目	记录	链接或说明
模型项目	Unitree Robotics UnifoLM-WMA-0-Dual	https://github.com/unitreerobotics/unifolm-world-model-action
赛事数据	ASC26 Embodied World Model Optimizations	https://github.com/ASC-Competition/ASC26-Embodied-World-Model-Optimization
模型权重	UnifoLM-WMA-0-Dual checkpoint	https://huggingface.co/unitreerobotics/UnifoLM-WMA-0-Dual
远程平台	AutoDL_3090；NVIDIA RTX 3090 24 GB；Linux 容器	SSH 端口 20740
Python 环境	Conda 环境 asc_wma；PyTorch、xformers、open_clip、h5py、imageio	依据项目依赖安装

表 1 软件、数据和实验环境记录

模型启动阶段加载 ViT-H-14 OpenCLIP 权重，并用图像特征形状、均值、标准差和有限性检查确认 image condition 可用。运行期间 GPU 显存占用约 22.8 GB，功耗观测约 348 W；报告中的时间比较是在同一远程实例、同一输入、同一 checkpoint 下完成的。

运行时的峰值内存也达到 33 GB 左右，可见，原本的 Colab 环境的配置是远远不能完成本实验的。

3 .官方基线复现

参数	取值
DDIM steps	50
frame_stride	4
video_length	16
n_action_steps / exe_steps	16 / 16
stackbox n_iter	7
cleanup_pencils n_iter	8
短测 n_iter	1
seed	123
timestep_spacing	uniform_trailing
guidance_rescale	0.7
ddim_eta	1.0

表 2 基线和正式优化共同采用的官方采样参数

基线版本仅修改数据路径和结果保存路径，调用原始 world_model_interaction.py；没有启用 AMP、fast_io、zero_pred_state 或其他优化开关。完整组和短测组分别单独运行并记录 real 时间及 PSNR，确保后续比较具有同一轮次口径。

基线输出目录分别为 /root/asc27_system_results/baseline_official_full_system 和 baseline_official_short_system。两组共生成 16 个 psnr.json 和 16 个完整 MP4；每个 case 的真实 wall-clock 时间来自对应 run.log。

4 .优化设计与实现

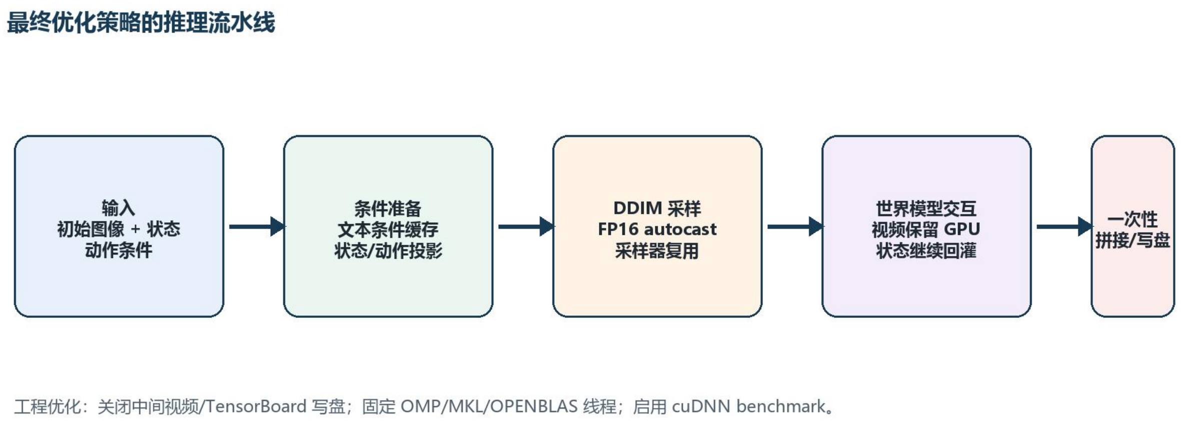
最终优化策略的推理流水线
输入
初始图像 + 状态
动作条件
条件准备
文本条件缓存
状态/动作投影
DDIM 采样
FP16 autocast
采样器复用
世界模型交互
视频保留 GPU
状态继续回灌
一次性
拼接/写盘
工程优化：关闭中间视频/TensorBoard 写盘；固定 OMP/MKL/OPENBLAS 线程；启用 cuDNN benchmark。

图 1 最终优化方案的数据流和计算流

实现时保留官方的视频长度、DDIM 步数、frame_stride 和完整交互轮次，主要处理重复计算、同步等待和不必要的 I/O。这里主要是看基线运行时，GPU 占用率忽高忽低，出现这种情况一般就是等待数据的问题了，所以就想办法优化一下 I/O 处理。可能改变结果口径的设置单独测试，再根据 PSNR 和稳定性决定是否使用。

4.1 不改变结果口径的工程优化

(1) 推理阶段使用 torch.no_grad，并将生成函数放在 no-grad 路径中，避免建立训练反向图和保存无用中间激活。前向算子和采样步数保持不变。

(2) 启用 CUDA FP16 autocast。模型 checkpoint 本身不被永久转换为半精度，主要计算在 autocast 上下文中执行；FP32 probe 显示完全 FP32 的速度只有约 1.28 ×，因此 FP16 是达到目标加速比的关键。

(3) fast_io 路径跳过动作分支视频解码、中间迭代视频、TensorBoard event 和逐轮 MP4 编码，只保留最终拼接视频及必要的 PSNR 文件。逐轮视频写盘会迫使 GPU 等待 CPU 编码和文件系统。

(4) 世界模型交互产生的 pred_videos_1 保留在 GPU 上，先在显存中累积每轮执行片段，全部迭代结束后再一次性拼接、传回 CPU 和编码，减少每轮 GPU-CPU 往返。

(5) DDIMSampler 对象挂在 model 上复用；文本 instruction 的 learned conditioning 按 prompt tuple 缓存，避免每次交互重复构造相同文本条件。图像条件不强行跨轮复用，因为交互后的图像会变化。

(6) 设置 torch.backends.cudnn.benchmark=True，并固定 OMP_NUM_THREADS、MKL_NUM_THREADS、OPENBLAS_NUM_THREADS=8，减少卷积算法选择和 CPU 线程过度竞争带来的抖动。

(7) OpenCLIP 权重在进程启动阶段加载并完成可用性检查，不在每一轮重新加载；日志级别降低，避免 PIL、h5py 等库的冗余输出淹没真正的推理阶段。

4.2 结果口径敏感的算法侧尝试

单独测试了 zero_pred_state。它在世界模型交互阶段不回灌预测状态，速度开销几乎不变；但在 stackbox case3 的对照中，AMP+fast_io+zero_pred_state 的 PSNR 为 24.2687 dB，关闭该开关为 26.2456 dB。因此保留预测状态，不启用 zero_pred_state。

DDIM 步数从 50 降到 30 的 probe 将完整组速度提高到约 3.6×，但 cleanup_pencils case1 的 PSNR 从约 20.94 dB 降到 19.31 dB，且没有改善 25 dB 门槛问题，因此只作为极限速度参考，不纳入最终方案。

torch.compile probe 受到 einops、xformers 和动态形状影响，出现 Dynamo cache-limit/recompilation 警告，首轮 CPU 占满而 GPU 利用率下降；CUDA Graph 的静态 Conv3D capture/replay 小探针可以通过，但完整链路包含随机噪声、动态条件和动态 shape，不能直接套用。两者均未纳入正式结果。

FP32+fast_io+不置零的 case3 probe 达到 26.7792 dB，但耗时 11m49.5s，约 1.28× 加速；它说明 FP32 更稳，却不满足题目希望达到的 1.7× 左右速度目标。最终采用 FP16 autocast 与不置零状态的折中。

4.3 最终运行配置

```
bash run_experiment.sh opt_amp_fastio_gpuaccum_nozero <scenario> <case> \
 50 <n_iter> 16 4 1 1.0 \
 scripts/evaluation/world_model_interaction_optimized.py \
 0 0.7 uniform_trailing 123 1.0 1
```

完整组的 n_iter 为 stackbox=7、cleanup_pencils=8；短测组仅把 n_iter 改为 1，其他选项完全相同。因此两组的差别只来自交互轮次。

5 .优化探针与取舍

方案	速度表现	质量/稳定性证据	纳入正式方案	结论
AMP + zero_state + fast_io	约 2.4×	stackbox case3 24.2687 dB	否	zero_pred_state 导致质量明显下降
AMP + fast_io + 不置零	约 2.4×	stackbox case3 26.2456 dB； cleanup case1 20.31 dB	是	正式最终方案
DDIM 50 → 30	约 3.6×	cleanup case1 19.3118 dB	否	速度极限参考
FP32 + fast_io + 不置零	约 1.28×	stackbox case3 26.7792 dB	否	质量较稳但速度不足
torch.compile	不稳定	动态重编译、GPU 利用率下降	否	完整链路不适合
CUDA Graph	静态小探针通过	完整链路存在动态条件/shape	否	只保留探针结论

表 3 优化探针、证据和最终取舍

6 .实验结果与分析

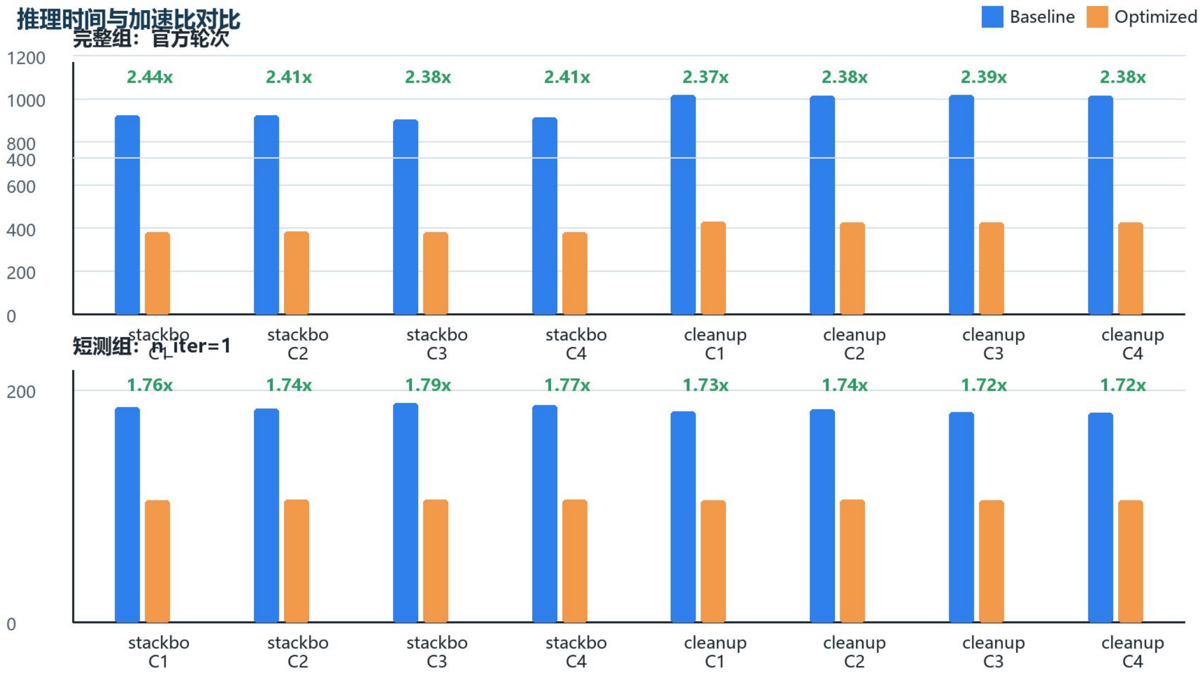

图 2 8 个完整样本和 8 个短测样本的时间对比；绿色标注为单 case 加速比

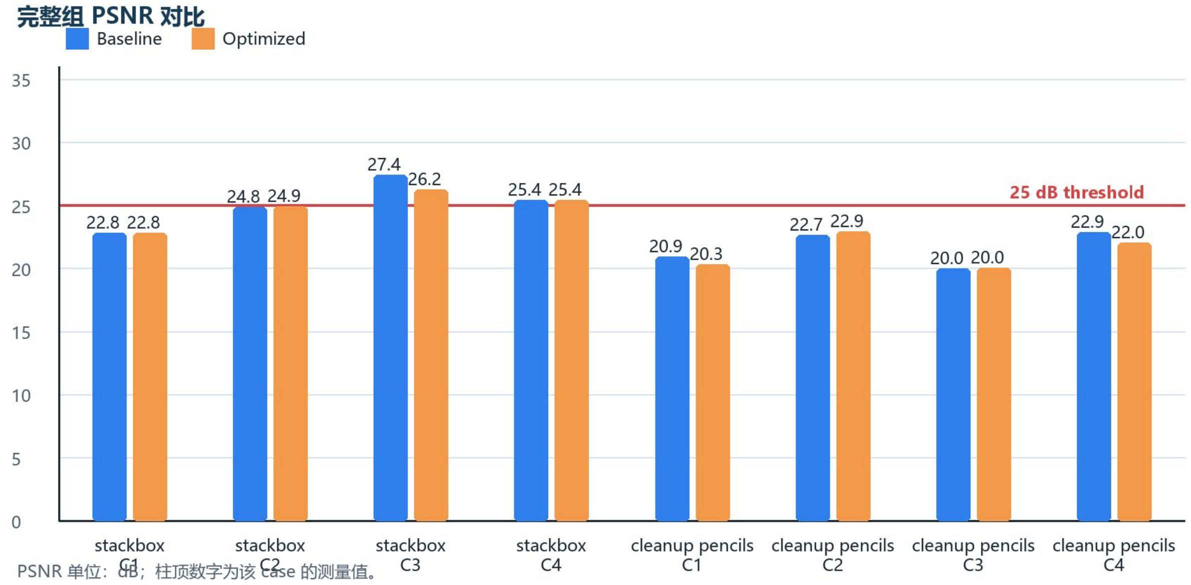

PSNR 单位：dB；柱顶数字为该 case 的测量值。

图 3 完整组 PSNR；红线为题面 25 dB 阈值

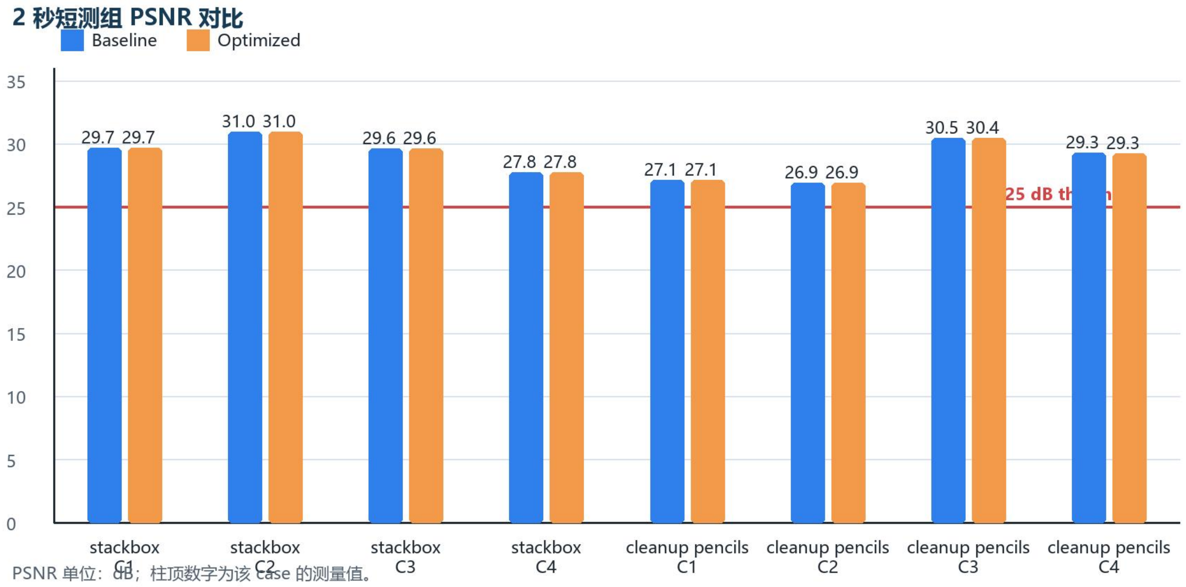

图 4 2 秒短测组 PSNR；红线为题面 25 dB 阈值

完整组平均从 23.38 dB 变为 23.09 dB，平均加速 2.395×。stackbox case1、case2、case4 的质量变化很小，case3 下降 1.19 dB；cleanup_pencils case2、case3 基本持平，case1 和 case4 分别下降 0.63 dB 和 0.86 dB。速度提升均高于 1.7×，质量下降主要出现在半精度和跨轮世界模型误差累积环节，I/O 修改本身没有明显影响。

短测组平均从 28.98 dB 变为 28.97 dB，平均加速 1.745×，8 个 case 全部高于 25 dB。短测只执行一次世界模型交互，因此误差不会经历完整组的多轮累积；这也解释了为什么短测 PSNR 通常明显高于完整组。

由于 GPU 推理、xformers 算子和半精度路径存在非完全确定性，同一配置重复运行的 PSNR 会有波动。例如 cleanup case1 的单独不置零 probe 为 21.2404 dB，而统一队列结果为 20.3101 dB。最终表格采用统一队列的单次结果，所有基线和优化结果均在同一批次内进行比较。

7 .运行过程展示

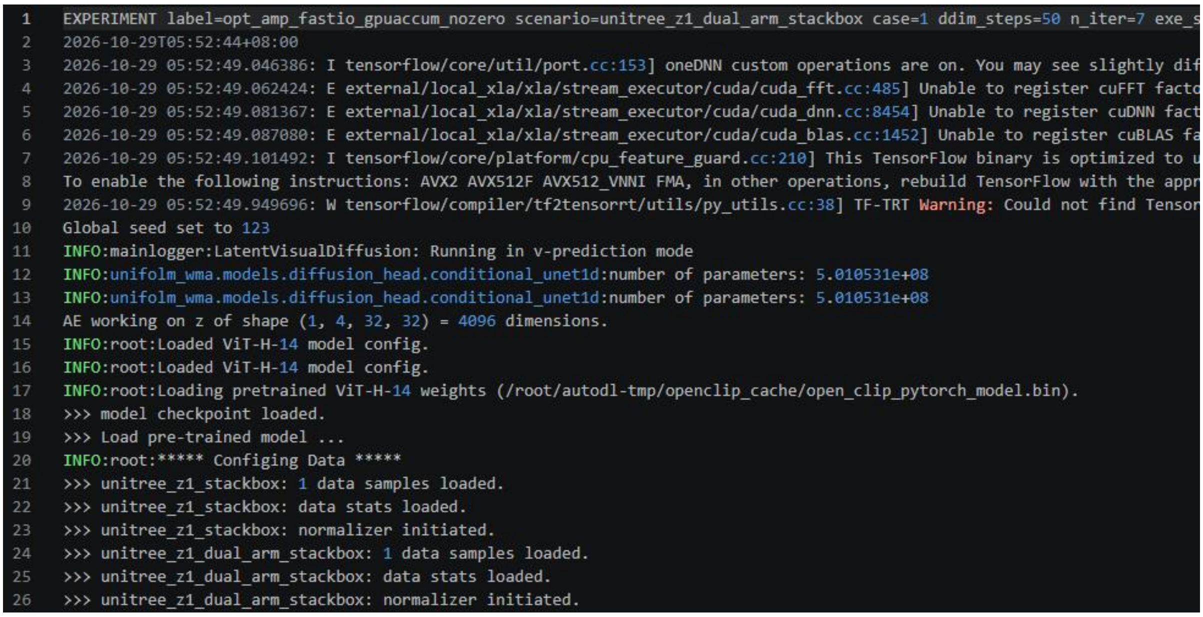

```
EXPERIMENT label=opt_amp_fastio_gpuaccum_nozero scenario=unitree_z1_dual_arm_stackbox case=1 ddim_steps=50 n_iter=7 exe_s
2026-10-29T05:52:44+08:00
2026-10-29 05:52:49.046386: I tensorflow/core/util/port.cc:153] oneDNN custom operations are on. You may see slightly dif
2026-10-29 05:52:49.062424: E external/local_xla/xla/stream_executor/cuda/cuda_fft.cc:485] Unable to register cuFFT facto
2026-10-29 05:52:49.081367: E external/local_xla/xla/stream_executor/cuda/cuda_dnn.cc:8454] Unable to register cuDNN fact
2026-10-29 05:52:49.087080: E external/local_xla/xla/stream_executor/cuda/cuda_blas.cc:1452] Unable to register cuBLAS fa
2026-10-29 05:52:49.101492: I tensorflow/core/platform/cpu_feature_guard.cc:210] This TensorFlow binary is optimized to u
To enable the following instructions: AVX2 AVX512F AVX512_VNNI FMA, in other operations, rebuild TensorFlow with the appr
2026-10-29 05:52:49.949696: W tensorflow/compiler/tf2tensorrt/utils/py_utils.cc:38] TF-TRT Warning: Could not find Tensor
Global seed set to 123
INFO:mainlogger:LatentVisualDiffusion: Running in v-prediction mode
INFO:unifolm_wma.models.diffusion_head.conditional_unet1d:number of parameters: 5.010531e+08
INFO:unifolm_wma.models.diffusion_head.conditional_unet1d:number of parameters: 5.010531e+08
AE working on z of shape (1, 4, 32, 32) = 4096 dimensions.
INFO:root:Loaded ViT-H-14 model config.
INFO:root:Loaded ViT-H-14 model config.
INFO:root:Loading pretrained ViT-H-14 weights (/root/autodl-tmp/openclip_cache/open_clip_pytorch_model.bin).
>>> model checkpoint loaded.
>>> Load pre-trained model ...
INFO:root:***** Configing Data *****
>>> unitree_z1_stackbox: 1 data samples loaded.
>>> unitree_z1_stackbox: data stats loaded.
>>> unitree_z1_stackbox: normalizer initiated.
>>> unitree_z1_dual_arm_stackbox: 1 data samples loaded.
>>> unitree_z1_dual_arm_stackbox: data stats loaded.
>>> unitree_z1_dual_arm_stackbox: normalizer initiated.
```

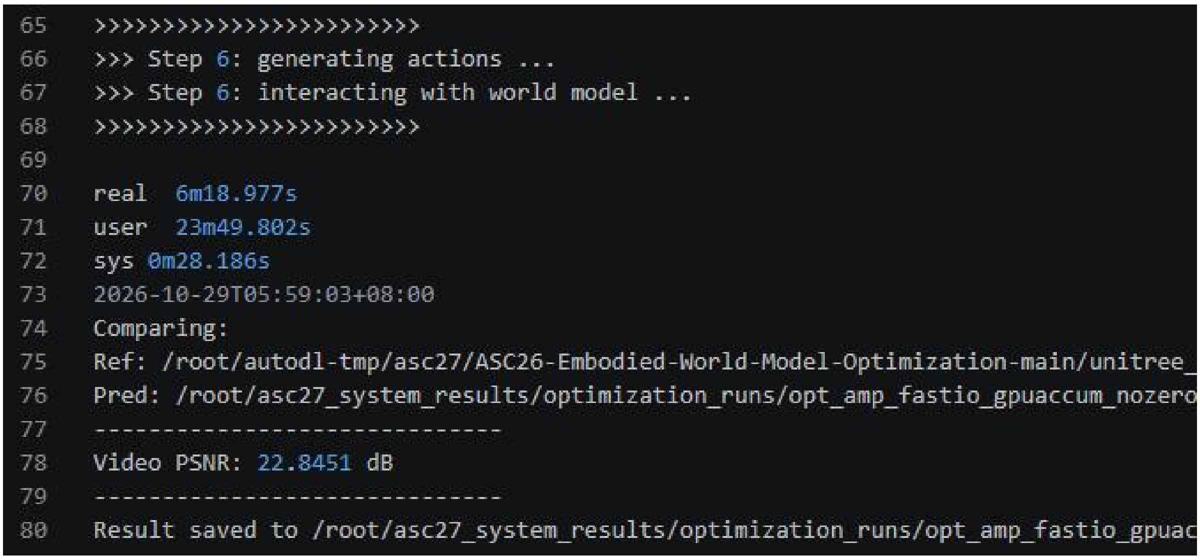

```
>>>>>>>>>>>>>>>>>>>>>>>>>
>>> Step 6: generating actions ...
>>> Step 6: interacting with world model ...
>>>>>>>>>>>>>>>>>>>>>>>>>

real  6m18.977s
user  23m49.802s
sys 0m28.186s
2026-10-29T05:59:03+08:00
Comparing:
Ref: /root/autodl-tmp/asc27/ASC26-Embodied-World-Model-Optimization-main/unitree_
Pred: /root/asc27_system_results/optimization_runs/opt_amp_fastio_gpuaccum_nozero
--------------------------------
Video PSNR: 22.8451 dB
--------------------------------
Result saved to /root/asc27_system_results/optimization_runs/opt_amp_fastio_gpuac
```

图 5 运行日志摘录：包含实验参数、real 时间和 PSNR 输出

7.1 运行界面截图

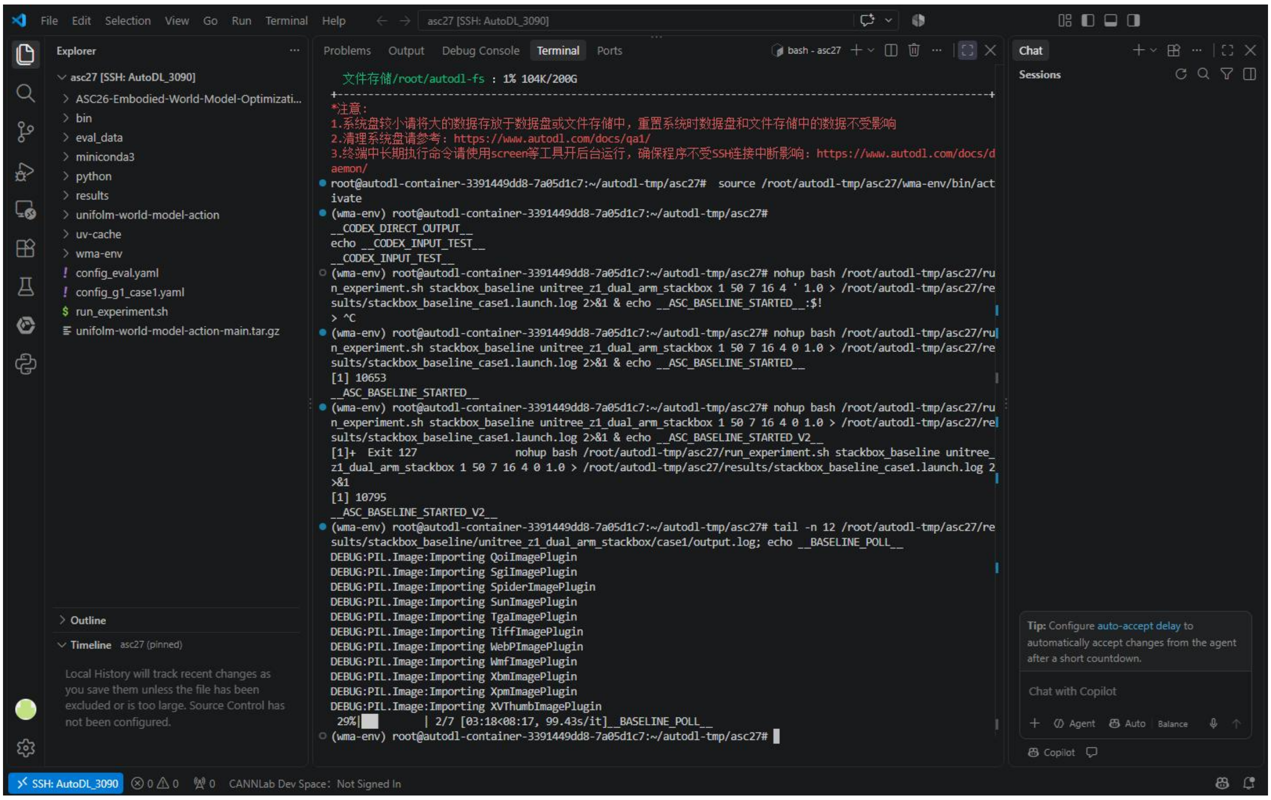
File
Edit
Selection
View
Go
Run
Terminal
Help
asc27 [SSH: AutoDL_3090]
Explorer
asc27 [SSH: AutoDL_3090]
ASC26-Embodied-World-Model-Optimizati...
bin
eval_data
miniconda3
python
results
unifolm-world-model-action
uv-cache
wma-env
config_eval.yaml
config_g1_case1.yaml
run_experiment.sh
unifolm-world-model-action-main.tar.gz
Outline
Timeline
asc27 (pinned)
Problems
Output
Debug Console
Terminal
Ports
bash - asc27
Chat
Sessions
Chat with Copilot
Agent
Auto
Balance
Copilot
SSH: AutoDL_3090
0
0
0
CANNLab Dev Space: Not Signed In

```
  文件存储/root/autodl-fs : 1% 104K/200G
+---------------------------------------------------------------------------------------------------+
*注意:
1.系统盘较小请将大的数据存放于数据盘或文件存储中，重置系统时数据盘和文件存储中的数据不受影响
2.清理系统盘请参考: https://www.autodl.com/docs/qa1/
3.终端中长期执行命令请使用screen等工具开后台运行，确保程序不受SSH连接中断影响: https://www.autodl.com/docs/d
aemon/
root@autodl-container-3391449dd8-7a05d1c7:~/autodl-tmp/asc27#  source /root/autodl-tmp/asc27/wma-env/bin/act
ivate
(wma-env) root@autodl-container-3391449dd8-7a05d1c7:~/autodl-tmp/asc27#
__CODEX_DIRECT_OUTPUT__
echo __CODEX_INPUT_TEST__
__CODEX_INPUT_TEST__
(wma-env) root@autodl-container-3391449dd8-7a05d1c7:~/autodl-tmp/asc27# nohup bash /root/autodl-tmp/asc27/ru
n_experiment.sh stackbox_baseline unitree_z1_dual_arm_stackbox 1 50 7 16 4 ' 1.0 > /root/autodl-tmp/asc27/re
sults/stackbox_baseline_case1.launch.log 2>&1 & echo __ASC_BASELINE_STARTED__:$!
> ^C
(wma-env) root@autodl-container-3391449dd8-7a05d1c7:~/autodl-tmp/asc27# nohup bash /root/autodl-tmp/asc27/ru
n_experiment.sh stackbox_baseline unitree_z1_dual_arm_stackbox 1 50 7 16 4 0 1.0 > /root/autodl-tmp/asc27/re
sults/stackbox_baseline_case1.launch.log 2>&1 & echo __ASC_BASELINE_STARTED__
[1] 10653
__ASC_BASELINE_STARTED__
(wma-env) root@autodl-container-3391449dd8-7a05d1c7:~/autodl-tmp/asc27# nohup bash /root/autodl-tmp/asc27/ru
n_experiment.sh stackbox_baseline unitree_z1_dual_arm_stackbox 1 50 7 16 4 0 1.0 > /root/autodl-tmp/asc27/re
sults/stackbox_baseline_case1.launch.log 2>&1 & echo __ASC_BASELINE_STARTED_V2__
[1]+  Exit 127                nohup bash /root/autodl-tmp/asc27/run_experiment.sh stackbox_baseline unitree_
z1_dual_arm_stackbox 1 50 7 16 4 0 1.0 > /root/autodl-tmp/asc27/results/stackbox_baseline_case1.launch.log 2
>&1
[1] 10795
__ASC_BASELINE_STARTED_V2__
(wma-env) root@autodl-container-3391449dd8-7a05d1c7:~/autodl-tmp/asc27# tail -n 12 /root/autodl-tmp/asc27/re
sults/stackbox_baseline/unitree_z1_dual_arm_stackbox/case1/output.log; echo __BASELINE_POLL__
DEBUG:PIL.Image:Importing QoiImagePlugin
DEBUG:PIL.Image:Importing SgiImagePlugin
DEBUG:PIL.Image:Importing SpiderImagePlugin
DEBUG:PIL.Image:Importing SunImagePlugin
DEBUG:PIL.Image:Importing TgaImagePlugin
DEBUG:PIL.Image:Importing TiffImagePlugin
DEBUG:PIL.Image:Importing WebPImagePlugin
DEBUG:PIL.Image:Importing WmfImagePlugin
DEBUG:PIL.Image:Importing XbmImagePlugin
DEBUG:PIL.Image:Importing XpmImagePlugin
DEBUG:PIL.Image:Importing XVThumbImagePlugin
 29%|██        | 2/7 [03:18<08:17, 99.43s/it]__BASELINE_POLL__
(wma-env) root@autodl-container-3391449dd8-7a05d1c7:~/autodl-tmp/asc27# █
```

Local History will track recent changes as you save them unless the file has been excluded or is too large. Source Control has not been configured.

Tip: Configure auto-accept delay to automatically accept changes from the agent after a short countdown.

图 6　运行界面截图

7.2 视频帧截图

full | unitree_z1_dual_arm_stackbox | case1 | PSNR 22.8451 dB

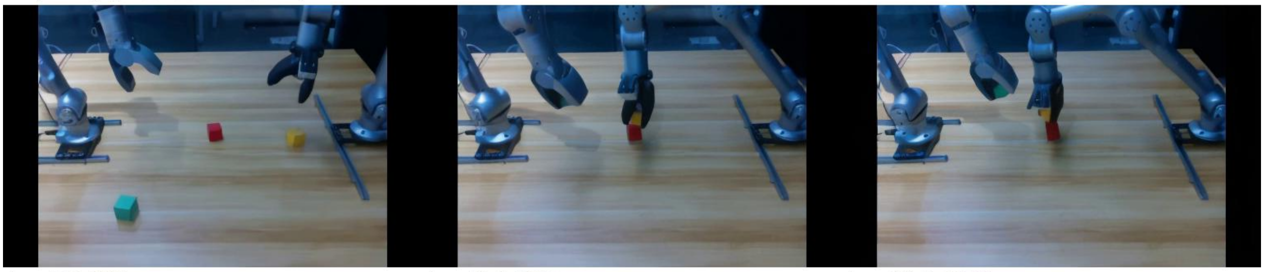

frame 0 | t=0.000s　　frame 56 | t=7.000s　　frame 111 | t=13.875s

full | unitree_z1_dual_arm_cleanup_pencils | case1 | PSNR 20.3101 dB

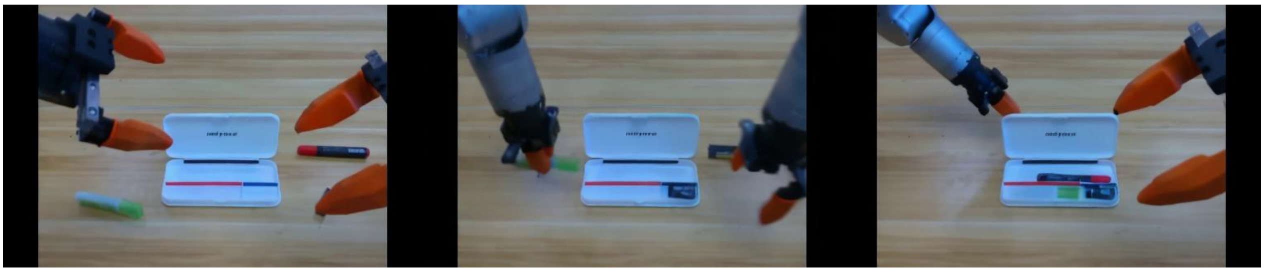

frame 0 | t=0.000s　　frame 64 | t=8.000s　　frame 127 | t=15.875s

图 7　视频帧截图 MP4 的首帧、中间帧和末帧

8 .结论与后续工作

本次工作完成了两个场景、两种轮次设置，以及基线、优化和评测。工程侧减少了中间视频编码、TensorBoard 写盘和 GPU-CPU 往返；算法侧通过 sampler/text cache 复用减少重复准备，并用 zero_state、DDIM30、FP32、torch.compile 与 CUDA Graph 探针检查速度和质量的变化。AMP+fast_io+保留预测状态的方案在完整组平均加速 2.395 ×，短测平均加速 1.745 × 。

附录 详细结果表

完整组

场景	**case**	**基线时间 (s)**	**优化时间 (s)**	**加速比**	**基线 PSNR**	**优化 PSNR**	**Δ PSNR**	**25dB**
stackbox	1	923.51	378.98	2.44	22.83	22.85	+0.01	未达标
stackbox	2	924.76	383.31	2.41	24.85	24.92	+0.07	未达标
stackbox	3	904.09	380.55	2.38	27.44	26.25	-1.19	达标
stackbox	4	914.49	380.11	2.41	25.40	25.40	-0.00	达标

附表 1 完整组 stackbox 详细结果

场景	**case**	**基线时间 (s)**	**优化时间 (s)**	**加速比**	**基线 PSNR**	**优化 PSNR**	**Δ PSNR**	**25dB**
cleanup_pencils	1	1017.97	429.45	2.37	20.94	20.31	-0.63	未达标
cleanup_pencils	2	1014.40	425.55	2.38	22.66	22.92	+0.26	未达标
cleanup_pencils	3	1016.89	425.28	2.39	19.99	20.02	+0.03	未达标
cleanup_pencils	4	1013.71	425.35	2.38	22.90	22.04	-0.86	未达标

附表 2 完整组 cleanup_pencils 详细结果

2 秒短测组

场景	**case**	**基线时间 (s)**	**优化时间 (s)**	**加速比**	**基线 PSNR**	**优化 PSNR**	**Δ PSNR**	**25dB**

场景	case	基线时间 (s)	优化时间 (s)	加速比	基线 PSNR	优化 PSNR	ΔPSNR	25dB
stackbox	1	185.05	105.15	1.76	29.68	29.66	-0.02	达标
stackbox	2	183.93	105.80	1.74	30.98	30.98	-0.00	达标
stackbox	3	188.79	105.69	1.79	29.63	29.65	+0.02	达标
stackbox	4	187.11	105.83	1.77	27.76	27.75	-0.00	达标

附表 3 2 秒短测组 stackbox 详细结果

场景	case	基线时间 (s)	优化时间 (s)	加速比	基线 PSNR	优化 PSNR	Δ PSNR	25dB
cleanup_pencils	1	181.79	105.20	1.73	27.11	27.14	+0.03	达标
cleanup_pencils	2	183.61	105.54	1.74	26.92	26.92	-0.00	达标
cleanup_pencils	3	181.05	105.19	1.72	30.46	30.43	-0.02	达标
cleanup_pencils	4	180.30	104.76	1.72	29.29	29.26	-0.03	达标

附表 4 2 秒短测组 cleanup_pencils 详细结果